

Teoría de Información y la Comunicación

Clase 6



Temas de la Unidad:

- ♣ Primer teorema de Shannon
- ♣ Rendimiento y redundancia de un Código
- ♣ Código de Huffman
- ♣ Código de Shannon-Fano

Unidad III: Codificación de Fuentes de Información

Considerar un alfabeto fuente $S = \{s_1, s_2, \dots, s_q\}$, con una distribución de probabilidades $P = \{p_1, p_2, \dots, p_q\}$ y un código instantáneo C construido utilizando un alfabeto $X = \{x_1, x_2, \dots, x_r\}$. Entonces como cada p_i está asociado a s_i y c_i , se puede obtener $H(S)$ y L la longitud media de C . En base a Kraft-MacMillan se puede afirmar que se cumple: $L \geq H(S)$. Y estaremos en presencia de un código compacto cuando: $p_i = r^{-l_i}$.

Encontrar un código óptimo implica hallar un código con longitudes l_i que cumplan con $p_i = r^{-l_i}$, pero esto no es trivial. El Código C en caso de ser óptimo, no puede tener una longitud media inferior a la entropía ($L \geq H(S)$). Esto también puede verse como una cota para la longitud media del código pues: **“No se puede comprimir más allá de la entropía”**.

$$H_r(S) \leq L \leq H_r(S) + 1$$

Estas cotas aplican a cualquier código instantáneo, considerando fuentes de memoria nula, entonces también se pueden aplicar a las extensiones de S :

$$H_r(S^n) \leq L_n \leq H_r(S^n) + 1$$

Unidad III: Codificación de Fuentes de Información

L_n representa la longitud media de las palabras correspondientes a los símbolos de la extensión de orden n de la fuente S . y llamemos Y_i a la longitud de la palabra correspondiente al símbolo σ_i y $P(\sigma_i)$ la probabilidad de σ_i , entonces :

$$L_n = \sum_{i=1}^{q^n} P(\sigma_i) * Y_i$$

Como L_n es el número medio de símbolos del alfabeto código que son necesarios para representar un símbolo del alfabeto fuente y como : $H_r(S^n) = n * H_r(S)$ se puede expresar que:

$$H_r(S) \leq \frac{L_n}{n} < H_r(S) + \frac{1}{n}$$

Ecuación que se conoce como Primer Teorema de Shannon o Teorema de la codificación sin ruido.

Unidad III: Codificación de Fuentes de Información

Siempre será posible encontrar un valor de $\frac{L_n}{n}$ tan próximo a $H_r(S)$ como queramos, sin más que codificar la extensión de orden n de S , en lugar de S :

$$\lim_{n \rightarrow \infty} \left(\frac{L_n}{n} \right) = H_r(S)$$

O sea número medio de símbolos r -arios correspondientes a un símbolo de la fuente puede hacerse tan pequeño, pero no inferior, a la entropía de la fuente expresada en unidades de orden r .

El precio que se paga por la disminución de $\frac{L_n}{n}$ es un aumento en la complejidad de la codificación debido al gran número (q^n) de símbolos de la fuente.

Si L es la longitud media de un código r -ario, unívoco en S . L no puede ser inferior a $H_r(S)$. Luego, se define el rendimiento o eficiencia de un código como: $\eta = H_r \frac{(S)}{L}$ y se define como redundancia del código a: $1 - \eta = \frac{(L - H_r(S))}{L}$

Mayor redundancia implica menor información, el η es máximo si $L = H_r(S)$ y $(1 - \eta)$ será mínimo si $L = H_r(S)$

Unidad III: Codificación de Fuentes de Información

Dados los siguientes códigos: y las probabilidades ($\frac{1}{2}$, $\frac{1}{4}$, $\frac{1}{8}$, $\frac{1}{8}$) del alfabeto fuente S:

$H(S) = 1.75$ bits

S	C_1	C_2	C_3	C_4	C_5
S_1	0	0	10	0	0
S_2	0	010	00	10	10
S_3	0	01	11	110	110
S_4	0	10	110	1110	111
L	1	1.75	2.25	1.875	1.75
H/L	1.75	1	0.778	0.933	1

Unidad III: Codificación de Fuentes de Información

Huffman:

Dado un alfabeto código binario se puede obtener un código instantáneo óptimo para una distribución dada, utilizando el algoritmo propuesto por David A. Huffman en 1952. Este procedimiento recursivo en cada paso, agrupa los símbolos menos probables para formar un nuevo símbolo.

1er paso:

Consideremos $S: \{s_1, s_2, \dots, s_q\}$ y $P \{p_1, p_2, \dots, p_q\}$.

- Se ordena las s_q símbolos en forma decreciente : $P_1 \geq P_2 \geq \dots \geq P_q$
- Se obtiene un S reducido combinando los símbolos menos probables en uno nuevo cuya probabilidad será la suma de sus probabilidades.
- El S reducido se reordena según sus probabilidades y se vuelve a reducir mediante el mismo procedimiento hasta llegar a un S con solo dos símbolos.


Unidad III: Codificación de Fuentes de Información

2do paso:


- Comenzado por la última fuente reducida se construyen códigos compactos para cada una de ellas.
- Fijarse que en el último código compacto binario de la última fuente reducida esté formado sólo por los símbolos 0 y 1.
- El paso del código compacto de una fuente reducida a la anterior
 - Copiar las palabras de código al símbolo de procedencia
 - Si el símbolo procede de la fusión de dos, la palabra se copia a los dos que se originaron, y para diferenciarlas se añade a la derecha el símbolo 0 a una, y 1 a la otra (de forma arbitraria)

Unidad III: Codificación de Fuentes de Información

Primer Paso:



Segundo Paso;



Unidad III: Codificación de Fuentes de Información

Código Shannon Fano:

Es un procedimiento subóptimo para construir un código, que alcanza una cota de $L \leq H(S) + 2$

Pasos:

- Ordenar las probabilidades en forma decreciente.
- Seleccionar K tal que $\left| \sum_{i=1}^k P_i - \sum_{i=k+1}^m P_i \right|$ sea mínima.
- Asignar un bit diferente a cada uno de los subconjuntos en que se divide el alfabeto fuente.
- Repetir el procedimiento para todos los subconjuntos.

Unidad III: Codificación de Fuentes de Información

S	P					
s_1	0.4	1	1			11
s_2	0.2		0			10
s_3	0.15	0	1	1		011
s_4	0.1			0		010
s_5	0.06		0	1	1	0011
s_6	0.04				0	0010
s_7	0.03			0	1	0001
s_8	0.02				0	0000