



La Ley de Zipf

Explorando la distribución de frecuencias en lenguaje natural

¿Qué es la Ley de Zipf?

Observación empírica

En muchos fenómenos naturales, la frecuencia de un elemento es **inversamente proporcional al lugar que ocupa la palabra en una lista ordenada**.

Origen histórico

Descubierta por **George Kingsley Zipf (1949)** al estudiar las frecuencias de palabras.



La Ley de Zipf en Lenguaje Natural



1

Jerarquía de frecuencias

La palabra más frecuente aparece $\sim 2\times$ más que la segunda, $\sim 3\times$ más que la tercera.

2

Distribución asimétrica

Pocas palabras muy frecuentes (artículos, preposiciones) y muchas palabras raras.

3

Poder predictivo

Permite modelar y predecir distribuciones de vocabulario en cualquier idioma.

El Código: Paso 0 — Cargar la lista de palabras

Función `getWords(words)`

```
def getWords(file):  
    text = open(file, "r", encoding="utf-8").read()  
    return ["".join(c for c in word.lower() if c.isalnum()) for word in text.split()]
```

El Código: Paso 1 — Extraer Probabilidades

Función `getProbs(words)`

- Calcula la **frecuencia relativa** de cada palabra única en el texto.

```
def getProbs(words):  
    alfa = list(set(words))  
    probs = [words.count(word) / len(words) for word in alfa]  
    return alfa, probs
```



La probabilidad de cada palabra es su cantidad de apariciones dividido entre el total de palabras.

El Código: Paso 2 — Ordenar Probabilidades

Función `sortProbs(words)`

- Ordena las palabras por probabilidad de **mayor a menor**.
- Retorna una lista de palabras junto con sus probabilidades normalizadas.

```
def sortProbs(alfa, probs):  
    sort = sorted(zip(probs, alfa), reverse=True)  
    alfa = [x[1] for x in sort]  
    probs = [x[0] for x in sort]  
    return alfa, probs
```

El Código: Paso 3 — Generar Distribución Zipf

```
def getZipf(count, s = 1):  
    const = 1 / sum(1 / (i + 1) ** s for i in range(count))  
    return [const / (i + 1) ** s for i in range(count)]
```


Función `getZipf(count, s)`

- Genera la distribución teórica: $P(r) = C / r^s$
- $s = 1$ es el exponente clásico de la Ley de Zipf.



Modificar el valor de **s** permite ajustar la "pendiente" de la distribución y modelar variaciones empíricas.

El Código: Paso 4 — Comparación



El script combina todos los pasos para mostrar la comparación directa: **$P(\text{palabra})_{\text{real}} \approx P(\text{palabra})_{\text{Zipf}}$** en las primeras 20 palabras del ranking.

Ejemplo: El Quijote

Frecuencias reales

Analizamos las frecuencias reales de palabras extraídas directamente del texto de Cervantes.

Distribución teórica


Comparamos los datos con la distribución teórica de Zipf para verificar el ajuste.


Verificación empírica

Comprobamos si el patrón se cumple en literatura clásica del siglo XVII.



Ajuste de la Ley de Zipf en Escala Log-Log





Conclusión



Precisión sorprendente

La Ley de Zipf describe patrones reales en lenguaje natural con una exactitud matemática notable.



Herramienta fundamental

Pilar esencial en el procesamiento de lenguaje natural y en la teoría de la información.



Leyes simples, fenómenos complejos

Demuestra que los sistemas más complejos obedecen leyes matemáticas elegantemente simples.